

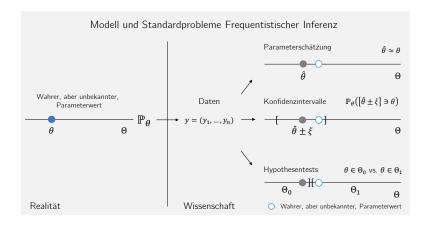
# **Tutorium**

# Wahrscheinlichketstheorie und Frequentistische Inferenz

BSc Psychologie WiSe 2022/23

Belinda Fleischmann

(12) Hypothesentests



## Selbstkontrollfragen

- 1. Erläutern Sie die grundlegende Logik statistischer Hypothesentests.
- 2. Geben Sie die Definition statistischer Hypothesen und eines Testszenarios wieder.
- 3. Definieren Sie die Begriffe der einfachen und zusammengesetzten Hypothesen.
- 4. Definieren Sie die Begriffe der einseitigen und zweiseitigen Hypothesen.
- Definieren Sie den Begriff des Tests.
- 6. Definieren Sie den Begriff des Standardtests.
- 7. Definieren Sie den Begriff des kritischen Bereichs eines Tests.
- 8. Definieren Sie den Begriff des Ablehungsbereichs eines Tests.
- 9. Definieren Sie den Begriff des kritischen Wert-basierten Tests.
- 10. Definieren Sie richtige Testentscheidungen, Typ I Fehler und Typ II Fehler.
- 11. Definieren Sie die Testgütefunktion.
- 12. Erläutern Sie die Bedeutung der Testgütefunktion im Rahmen der Konstruktion statistischer Tests.
- 13. Definieren Sie die Begriffe des Signifikanniveaus und des Level- $lpha_0$ -Tests.
- 14. Definieren Sie den Begriff des Testumfangs.
- 15. Erläutern Sie die prinzipielle Strategie zur Wahl von Null- und Alternativhypothesen in der Wissenschaft.
- 16. Erläutern Sie zentrale Schritte zur Konstruktion eines Hypothesentests.

### Selbstkontrollfragen

- 17. Formulieren Sie das statistische Modell eines Einstichproben-T-Tests.
- 18. Formulieren Sie die einfache Nullhypothese und zusammengesetzte Alternativhypothese dieses Tests.
- 19. Definieren Sie den zweiseitigen Einstichproben-T-Test (ZETT).
- 20. Skizzieren Sie qualitativ die Testgütefunktionen eines ZETTs für verschiedene kritische Werte.
- 21. Wie muss der kritische Wert eines ZETTs definiert sein, damit der Test ein Level- $\alpha_0$ -Test ist?
- 22. Skizzieren Sie qualitativ die Bestimmung des kritischen Wertes  $k_{\alpha 0}$  bei einem zws Einstichproben-T-Test.
- 23. Erläutern Sie das praktische Vorgehen zur Durchführung eines ZETTs.
- 24. Von welchen Werten hängt die Powerfunktion eines ZETTs ab?
- 25. Skizzieren Sie qualitativ die Powerfunktion des ZETTs bei fester Stichprobengröße.
- 26. Skizzieren Sie qualitativ die Powerfunktion des ZETTs bei festem Erwartungswertparameter.
- 27. Erläutern Sie das favorisierte praktische Vorgehen zur Durchführung einer Poweranalyse.
- 28. Erläutern Sie die Motivation zur Auswertung von p-Werten.
- 29. Definieren Sie den Begriff des p-Werts.
- 30. Geben Sie das Theorem zur Dualität von Konfidenzintervallen und Hypothesentests wieder.
- 31. Erläutern Sie die Dualität von Konfidenzintervallen und Hypothesentests.

### SKF 1. Logik statistischer Hypothesentests

# 1. Erläutern Sie die grundlegende Logik statistischer Hypothesentests.

Man hat einen Datensatz  $y_1,...,y_n$  vorliegen und nimmt an, dass es sich dabei um die Realisation einer Stichprobe handelt, zum Beispiel von  $v_1,...,v_n \sim N(\mu,\sigma^2)$ .

Man berechnet basierend auf dem Datensatz eine **Teststatistik**, zum Beispiel das anhand der Stichprobenvarianz und der Stichprobengröße normalisierte Stichprobenmittel  $\sqrt{n}\bar{y}_n/s_n$ .

Man fragt sich, wie wahrscheinlich es wäre, den beobachteten oder einen extremeren Wert der Teststatistik unter der Annahme eines Nullmodels zu observieren. Dabei meint man mit Nullmodell intuitiv ein Wahrscheinlichkeitsverteilungsmodell bei dem kein "interessanter Effekt" vorliegt, also zum Beispiel  $\mu=0$  gilt. Die Wahrscheinlichkeit ist wie immer Frequentistisch zu verstehen, d.h. als idealisierte relative Häufigkeit, wenn man viele Stichprobenrealisationen des Nullmodels generieren würde.

Ist die betrachtete Wahrscheinlichkeit dafür, den beobachteten oder einen extremeren Wert der Teststatistik unter Annahme des Nullmodells zu observieren groß, so sagt man sich "Nunja, dann ist es wohl ganz plausibel, dass das Nullmodel die Daten generiert hat". Im Wissenschaftsjargon spricht man von einem "nicht-signifikanten Ergebnis".

Ist die betrachtete Wahrscheinlichkeit dafür, den beobachteten oder einen extremeren Wert der Teststatistik unter Annahme des Nullmodells zu observieren dagegen klein, so sagt man sich "Aha, dann ist es wohl nicht so plausibel, dass das Nullmodel die Daten generiert hat". Im Wissenschaftsjargon spricht man von einem "signifikanten Ergebnis".

Wie immer in der Frequentistischen Statistik weiß man nach Durchführung dieser Prozedur nicht, ob im vorliegenden Fall nun wirklich das Nullmodel oder ein anderes Modell die Daten generiert hat, sondern man weiß nur, wie oft man bei dieser Prozedur im Mittel richtig oder falsch liegen würde, wenn alle Annahmen zuträfen und man diese Prozedur sehr oft wiederholen würde.

## SKF 2. Statistische Hypothesen und Testszenarios

2. Geben Sie die Definition statistischer Hypothesen und eines Testszenarios wieder.

# Definition (Statistische Hypothesen und Testszenario)

 $v_1,...,v_n\sim p_\theta$  sei eine Stichprobe mit WMF oder WDF  $p_\theta,\,\mathcal{Y}$  sei der Ergebnisraum des Zufallsvektors  $v:=(v_1,...,v_n)$ , und  $\Theta$  sei der Parameterraum des zugrundeliegenden statistischen Modells. Weiterhin sei  $\{\Theta_0,\Theta_1\}$  eine Partition des Parameterraumes, so dass  $\Theta=\Theta_0\cup\Theta_1$  und  $\Theta_0\cap\Theta_1=\emptyset$  gelten. Eine statistische Hypothese ist dann eine Aussage über den wahren, aber unbekannten, Parameterwert  $\theta$  in Hinblick auf die Untermengen  $\Theta_0$  und  $\Theta_1$  des Parameterraums. Speziell werden die Aussagen

- $\theta \in \Theta_0$  als Nullhypothese  $H_0$
- $\theta \in \Theta_1$  als Alternativhypothese  $H_1$

bezeichnet. Die Einheit aus Stichprobe, Ergebnisraum, Parameterraum, und Hypothesen wird im Folgenden als Testszenario bezeichnet.

### SKF 3. Einfache und zusammengesetzte Hypothesen

3. Definieren Sie die Begriffe der einfachen und zusammengesetzten Hypothesen.

# Definition (Einfache und zusammengesetzte Hypothesen)

Für statistische Hypothesen  $\Theta_i$ , i = 0, 1 gilt:

- Enthält  $\Theta_i$  nur ein einziges Element, so heißt  $\Theta_i$  einfach.
- Enthält  $\Theta_i$  mehr als ein Element, so heißt  $\Theta_i$  zusammengesetzt.

- Die Nullhypothese  $\Theta_0 = \{0\}$  ist ein Beispiel für eine einfache Hypothese.
- Bei einer einfachen Hypothese ist die Wahrscheinlichkeitsverteilung von v genau festgelegt.
- ullet Bei einer zusammengesetzten Hypothese ist nur die Verteilungsklasse von v festgelegt.

## 4. Definieren Sie die Begriffe der einseitigen und zweiseitigen Hypothesen.

# Definition (Einseitige und zweiseitige Hypothesen)

 $\Theta:=\mathbb{R}$  sei ein eindimensionaler Parameterraum und  $\theta_0$  sei ein Element von  $\Theta.$  Dann werden zusammengesetzte Nullhypothesen der Form

$$\Theta_0 := ]-\infty, \theta_0] \text{ oder } \Theta_0 := [\theta_0, \infty[$$
 (1)

einseitige Nullhypothesen genannt und auch in der Form

$$H_0: \theta \le \theta_0 \text{ oder } H_0: \theta \ge \theta_0$$
 (2)

geschrieben. Die entsprechenden Alternativhypothesen haben dabei die Form

$$\Theta_1 := ]\theta_0, \infty[ \text{ oder } \Theta_1 := ]-\infty, \theta_0[ \text{ bzw. } H_1 : \theta > \theta_0 \text{ oder } H_1 : \theta < \theta_0.$$
 (3)

Bei einer einfachen Nullhypothese der Form

$$\Theta_0 := \{\theta_0\} \text{ bzw. } H_0 : \theta = \theta_0 \tag{4}$$

wird die Alternativhypothese

$$\Theta_1 := \Theta \setminus \{\theta_0\} \text{ bzw. } H_1 : \theta \neq \theta_0 \Leftrightarrow \Theta_1 := ] - \infty, \theta_0[ \cup ]\theta_0, \infty[$$
 (5)

zweiseitige Alternativhypothese genannt.

# 5. Definieren Sie den Begriff des Tests.

# Definition (Test)

In einem Testszenario ist ein Test  $\phi$  eine Abbildung aus dem Ergebnisraum  $\mathcal{Y}$  nach  $\{0,1\}$ ,

$$\phi: \mathcal{Y} \to \{0, 1\}, y \mapsto \phi(y). \tag{6}$$

#### Dabei repräsentiert

- $\phi(y) = 0$  den Vorgang des Nichtablehnens der Nullhypothese.
- ullet  $\phi(y)=1$  den Vorgang des Ablehnens der Nullhypothese.

#### Bemerkung

• Weil y eine Realisation von v ist, ist  $\phi(y)$  eine Realisation von  $\phi(v)$ .

# 6. Definieren Sie den Begriff des Standardtests.

## Definition (Standardtest)

Ein Standardtest ist definiert durch die Verkettung einer Teststatistik

$$\gamma: \mathcal{Y} \to \mathbb{R}$$
 (7)

und einer Entscheidungsregel

$$\delta: \mathbb{R} \to \{0, 1\}. \tag{8}$$

Ein Standardtest kann also geschrieben werden als

$$\phi := \delta \circ \gamma : \mathcal{Y} \to \{0, 1\}. \tag{9}$$

- Weil y eine Realisation von v ist, ist  $\gamma(y) \in \mathbb{R}$  eine Realisation von  $\gamma(v)$ .
- Weil  $\gamma(y)$  eine Realisation von  $\gamma(v)$  ist, ist  $(\delta \circ \gamma)(y)$  eine Realisation von  $(\delta \circ \gamma)(v)$ .
- · Wir betrachten in der Folge nur Standardtests.

# 7. Definieren Sie den Begriff des kritischen Bereichs eines Tests.

# Definition (Kritischer Bereich)

Die Untermenge K des Ergebnisraums des Zufallsvektors  $v:=(v_1,...,v_n)$ , für die ein Test den Wert 1 annimmt, heißt kritischer Bereich des Tests,

$$K := \{ y \in \mathcal{Y} | \phi(y) = 1 \} \subset \mathcal{Y}. \tag{10}$$

- Die Ereignisse  $\{\phi(v)=1\}$  und  $\{v\in K\}$  sind äquivalent.
- Die Ereignisse  $\{\phi(v)=1\}$  und  $\{v\in K\}$  haben die gleiche Wahrscheinlichkeit.

## SKF 8. Ablehungsbereich

8. Definieren Sie den Begriff des Ablehungsbereichs eines Tests.

# Definition (Ablehnungsbereich)

Die Untermenge A des Ergebnisraums einer Teststatistik, für die der Test den Wert 1 annimmt, heißt Ablehnungsbereich des Tests,

$$A := \{ \gamma(y) \in \mathbb{R} | \phi(y) = 1 \} \subset \mathbb{R}. \tag{11}$$

- Die Ereignisse  $\{\phi(v)=1\}$  und  $\{\gamma(v)\in A\}$  sind äquivalent.
- Die Ereignisse  $\{\phi(v)=1\}$  und  $\{\gamma(v)\in A\}$  haben die gleiche Wahrscheinlichkeit.

# 9. Definieren Sie den Begriff des kritischen Wert-basierten Tests.

## Definition (Kritischer Wert-basierte Tests)

Ein kritischer Wert-basierter Test ist ein Standardtest, bei dem die Entscheidungsregel  $\delta$  von einem kritischen Wert  $k \in \mathbb{R}$  abhängt. Speziell ist

• ein einseitiger kritischer Wert-basierter Test von der Form

$$\phi: \mathcal{Y} \to \{0, 1\}, y \mapsto \phi(y) := 1_{\{\gamma(y) \ge k\}} = \begin{cases} 1 & \gamma(y) \ge k \\ 0 & \gamma(y) < k \end{cases}$$
 (12)

• ein zweiseitiger kritischer Wert-basierter Test von der Form

$$\phi: \mathcal{Y} \to \{0, 1\}, y \mapsto \phi(y) := 1_{\{|\gamma(y)| \ge k\}} = \begin{cases} 1 & |\gamma(y)| \ge k \\ 0 & |\gamma(y)| < k \end{cases}$$
(13)

# SKF 10. Testentscheidungen

10. Definieren Sie richtige Testentscheidungen, Typ I Fehler und Typ II Fehler.

# Definition (Richtige Testentscheidungen und Testfehler)

Das Nichtablehnen der Nullhypothese, wenn die Nullhypothese zutrifft werden, sowie das Ablehnen der Nullhypothese, wenn die Nullhypothese nicht zutrifft, werden richtige Testentscheidungen genannt. Es können weiterhin zwei Arten von Testfehlern auftreten: das Ablehnen der Nullhypothese, wenn die Nullhypothese zutrifft, heißt Typ I Fehler, das Nichtablehnen der Nullhypothese, wenn die Alternativhypothese zutrifft, heißt Typ II Fehler.

	Testentscheidung		
Wahrer Parameterwert		$\phi(y) = 0$	$\phi(y) = 1$
	$\theta \in \Theta_0$	Richtige Entscheidung	Typ I Fehler
	$\theta \in \Theta_1$	Typ II Fehler	Richtige Entscheidung

## 11. Definieren Sie die Testgütefunktion.

# Definition (Testgütefunktion)

Für einen Test  $\phi$  ist die Testgütefunktion definiert als

$$q_{\phi}: \Theta \to [0,1], \theta \mapsto q_{\phi}(\theta) := \mathbb{P}_{\theta}(\phi = 1).$$
 (14)

Für  $\theta \in \Theta_1$  heißt  $q_\phi$  auch Powerfunktion oder Trennschärfefunktion.

- Wir verzichten hier und im Folgenden auf die explizite Notation der Abhängigkeit von  $\phi$  von v.
- $\mathbb{P}_{\theta}$  bezeichnet die Verteilung von  $\phi$  unter der Annahme  $v_1, ..., v_n \sim p_{\theta}$ .
- Es gilt  $\mathbb{P}_{\theta}$  ( $\phi = 1$ ) =  $\mathbb{P}_{\theta}$  ( $v \in K$ ) =  $\mathbb{P}_{\theta}$  ( $\gamma \in A$ )
- Bei Poweranalysen betrachtet man  $q_{\phi}$  als Funktion aller Testszenarien und Testparameter.
- Ändert sich  $\phi$ , z.B. weil sich der kritische Wert von  $\phi$  ändert, dann ändert sich  $q_{\phi}(\theta)$ .

# 12. Erläutern Sie die Bedeutung der Testgütefunktion im Rahmen der Konstruktion statistischer Tests.

Wir wollen statistische Tests so konstruieren, dass die Wahrscheinlichkeit für Testfehler möglichst gering ist.

- Mithilfe der Testgütefunktion k\u00f6nnen wir die Wahrscheinlichkeiten f\u00fcr φ = 1 (Nullhypothese H<sub>0</sub> wird abgelehnt), und somit auch die Wahrscheinlichkeit f\u00fcr einen Typ I Fehler betrachten.
- Für jedes  $\theta \in \Theta$  (wobei  $\Theta = \Theta_0 \cup \Theta_1$ ) liefert  $q_\phi$  die Wahrscheinlichkeit, dass  $H_0$  durch  $\phi$  abgelehnt wird.
- Im Idealfall hätte man einen Test φ mit

$$q_{\phi}(\theta) = \mathbb{P}_{\theta}(\phi = 1) = 0$$
 für  $\theta \in \Theta_0$  und  $q_{\phi}(\theta) = \mathbb{P}_{\theta}(\phi = 1) = 1$  für  $\theta \in \Theta_1$ .

Die Testentscheidung eines solchen  $\phi$  wäre mit Wahrscheinlichkeit 1 richtig.

•  $\Rightarrow$  Gut sind kleine Werte von  $q_{\phi}$  für  $\theta \in \Theta_0$  und große Werte von  $q_{\phi}$  für  $\theta \in \Theta_1$ .

Generell gibt es Abhängigkeiten zwischen den Werten von  $q_{\phi}$  für  $\theta \in \Theta_0$  und  $\theta \in \Theta_1$ :

- Sei zum Beispiel  $\phi_a$  der Test definiert durch  $\phi_a(y):=0$  für alle  $y\in\mathcal{Y}$ , also der Test, der die Nullhypothese, unabhängig von den beobachteten Daten, *niemals ablehnt*. Für diesen Test gilt  $q_{\phi_a}(\theta)=0$  für  $\theta\in\Theta_0$ . Allerdings gilt für diesen Test auch  $q_{\phi_a}(\theta)=0$  für  $\theta\in\Theta_1$ .
- Andersherum sei  $\phi_b$  der Test definiert durch  $\phi_b(y):=1$  für alle  $y\in\mathcal{Y}$ , also ein Test, der die Nullhypothese, unabhängig von den beobachteten Daten, *immer ablehnt*. Für diesen Test gilt  $q_{\phi_b}(\theta)=1$  für  $\theta\in\Theta_1$ . Allerdings gilt für diesen Test auch  $q_{\phi_b}(\theta)=1$  für  $\theta\in\Theta_0$ .

# SKF 12. Bedeutung der Testgütefunktion (fortgeführt)

In der Konstruktion eines Tests muss also eine angemessene Balance zwischen

- kleinen Werten von  $q_\phi$  für  $\theta \in \Theta_0$  und
- großen Werten von  $q_\phi$  für  $\theta \in \Theta_1$  gefunden werden.

Die populärste Methode, eine solche Balance zu finden, ist in einem ersten Schritt ein  $\alpha_0 \in [0,1]$  zu wählen und sicher zu stellen, dass

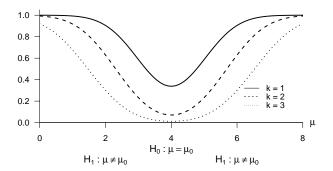
$$q_{\phi}(\theta) \le \alpha_0$$
 für alle  $\theta \in \Theta_0$ . (15)

- Eine konventionelle Wahl für sein solches  $\alpha_0$  ist zum Beispiel  $\alpha_0 := 0.05$ .
- Unter allen Tests und statistischen Modellen, die Ungleichung (15) erfüllen, wird man dann einen Test oder ein statistisches Modell auswählen, so dass  $q_{\phi}(\theta)$  für  $\theta \in \Theta_1$  so groß wie möglich ist.

# Einstichproben-T-Test | (4) Analyse der Testgütefunktion)

Testgütefunktion  $q_{\phi}$  für  $\sigma^2=9, \mu_0=4, n=12$  und k=1,2,3.

$$q_{\phi}(\mu) = \mathbb{P}_{\mu}(\phi = 1)$$



### SKF 13. Signifikanniveaus und des Level- $\alpha_0$ -Test

13. Definieren Sie die Begriffe des Signifikanniveaus und des Level- $\alpha_0$ -Tests.

# Definition (Level- $\alpha_0$ -Test, Signifikanzlevel $\alpha_0$ )

 $q_\phi$  sei die Testgütefunktion eines Tests  $\phi$  und es sei  $lpha_0 \in [0,1]$ . Dann heißt ein Test  $\phi$ , für den gilt, dass

$$q_{\phi}(\theta) \le \alpha_0$$
 für alle  $\theta \in \Theta_0$  (16)

ein Level- $\alpha_0$ -Test und man sagt, dass der Test das Signifikanzlevel  $\alpha_0$  hat.

# 14. Definieren Sie den Begriff des Testumfangs.

# Definition (Testumfang $\alpha$ )

Es sei  $\phi$  ein Level- $\alpha_0$ -Test mit Signifikanzlevel  $\alpha_0$ . Die Zahl

$$\alpha := \max_{\theta \in \Theta_0} q_{\phi}(\theta) \in [0, 1] \tag{17}$$

heißt der Testumfang von  $\phi$ .

- $\alpha$  ist die größtmögliche Wahrscheinlichkeit für einen Typ I Fehler.
- Ein Test ist dann, und nur dann, ein Level- $\alpha_0$ -Test, wenn  $\alpha \leq \alpha_0$  gilt.
- Bei einer einfachen Nullhypothese gilt für den Testumfang, dass  $\alpha=q_\phi(\theta_0)=\mathbb{P}_{\theta_0}(\phi=1).$

# 15. Erläutern Sie die prinzipielle Strategie zur Wahl von Null- und Alternativhypothesen in der Wissenschaft.

Das Vorgehen in der Testkonstruktion zunächst durch die Wahl eines Signifikanzlevels den Testumfang zu begrenzen und erst in einem zweiten Schritt dafür zu sorgen, dass die Wahrscheinlichkeit von  $\phi=1$  bei  $\theta\in\Theta_1$  bei diesem Signifikanzlevel möglichst groß ist, induziert eine **Asymmetrie in der Behandlung von Null- und Alternativhypothese**. Implizit wichtet man mit diesem Vorgehen Typ I Fehler als schwerwiegender als Typ II Fehler.

Dies wiederum impliziert eine mögliche Strategie zur Festlegung von Null- und Alternativhypothese:

- Die Nullhypothese ist die Hypothese, hinsichtlich deren assoziierter Testentscheidung man eher keinen Fehler machen möchte bzw. deren Fehlerwahrscheinlichkeit man primär kontrollieren möchte.
- In der wissenschaftlichen Anwendung ist es Standard, die falsche Konfirmation der eigenen Theorie als einen schwerwiegenderen Fehler als die falsche Ablehnung der eigenen Theorie zu werten.
- ⇒ Die falsche Konfirmation der eigenen Theorie sollte also ein Typ I Fehler, das falsche Ablehnen der eigenen Theorie ein Typ II Fehler sein.
- Damit die falsche Konfirmation der eigenen Theorie einen Typ I Fehler, also das Ablehnen von H<sub>0</sub> bei Zutreffen von H<sub>0</sub>, darstellt, muss die eigene Theorie als Alternativhypothese aufgestellt werden.
- Die Alternativhypothese fälschlichweise Abzulehnen wird damit ein Typ II Fehler.

## SKF 16. Konstruktion eines Hypothesentests

# 16. Erläutern Sie zentrale Schritte zur Konstruktion eines Hypothesentests.

- (1) Statistisches Modell und Testhypothesen
- (2) Definition und Analyse der Teststatistik
- (3) Definition des Tests
- (4) Analyse der Testgütefunktion
- (5) Testumfangkontrolle
- (6) Analyse der Powerfunktion

# 17. Formulieren Sie das statistische Modell eines Einstichproben-T-Tests.

Das Statistische Modell des Einstichproben-T-Tests ist definiert als

$$v_i = \mu + \varepsilon_i \text{ mit } \varepsilon_i \sim N(0, \sigma^2) \text{ für } i = 1, ..., n$$
 (18)

wobei

- $v_i, i = 1, ..., n$  beobachtbare Zufallsvariablen,
- $\mu$  den wahren, aber unbekannten, Erwartungswertparameter der Stichprobenvariablen,
- $\sigma^2 > 0$  den Varianzparameter der  $\varepsilon_i$

bezeichnen.

Dieses Modell ist äquivalent zum Normalverteilungsmodell

$$v = v_1, ..., v_n \sim N(\mu, \sigma^2), \tag{19}$$

also der Annahme unabhängig und identisch normalverteilter Stichprobenvariablen mit Erwartungswertparameter  $\mu$  und Varianzparameter  $\sigma^2$ .

### SKF 18. Hypothesen beim Einstichproben-T-Test

# 18. Formulieren Sie die einfache Nullhypothese und zusammengesetzte Alternativhypothese dieses Tests.

Für ein  $\mu_0$  betrachten wir die einfache Nullhypothese und die zusammengesetzte Alternativhypothese

$$H_0: \mu = \mu_0 \Leftrightarrow \Theta_0 := \{\mu_0\} \text{ und } H_1: \mu \neq \mu_0 \Leftrightarrow \Theta_1 := \mathbb{R} \setminus \{\mu_0\},$$
 (20)

respektive.

Bezogen auf das Anwendungsbeispiel ist hier  $\mu_0 := 0$  von Interesse:

- $H_0: \mu=0$  entspricht der Hypothese keines Effekts der Therapie auf die BDI Score Reduktion.
- ullet  $H_1: \mu 
  eq 0$  entspricht der Hypothese eines Effekts der Therapie auf die BDI Score Reduktion.

## SKF 19. zweiseitiger Einstichproben-T-Test (ZETT)

19. Definieren Sie den zweiseitigen Einstichproben-T-Test (ZETT).

$$\phi(v) := 1_{\{|T| \ge k\}} = \begin{cases} 1 & |T| \ge k \\ 0 & |T| < k \end{cases}.$$

# Einstichproben-T-Test | (2) Definition und Analyse der Teststatistik

## Definition (Einstichproben-T-Teststatistik)

 $v_1,...,v_n\sim N(\mu,\sigma^2)$  sei die Stichprobe eines Normalverteilungmodells,  $\bar{v}$  bezeichne das Stichprobenmittel, Sbezeichne die Stichprobenstandardabweichung und es sei  $\mu_0 \in \mathbb{R}$ . Dann ist die T-Teststatistik definiert als

$$T := \sqrt{n} \left( \frac{\bar{v} - \mu_0}{S} \right). \tag{21}$$

- Im Gegensatz zur T-Konfidenintervallstatistik muss bei der T-Teststatistik nicht μ<sub>0</sub> = μ gelten.
- Intuitiv kann die T-Teststatistik als mit der Stichprobengröße (Evidenz) gewichtetes Verhältnis von Signal (sytematischer Variabilität) zu Rauschen (unsystematischer Variabilität) verstanden werden:

$$\sqrt{\text{Stichprobengr\"oße}}\left(\frac{\text{Signal}}{\text{Rauschen}}\right) = \sqrt{n}\left(\frac{\bar{v} - \mu_0}{S}\right) \tag{22}$$

- Die T-Teststastitik ist eine skalare Deskription des Effekt vs. Variabilität Verhältnisses eines Datensatzes.
- In der T-Teststatistik wird die Effektgröße in Einheiten der Stichprobenstandardabweichung gemessen:

$$\circ$$
  $T = 1 \Leftrightarrow \sqrt{n}(\bar{v} - \mu_0) = 1S$ 

$$\circ$$
  $T = 2 \Leftrightarrow \sqrt{n}(\bar{v} - \mu_0) = 2S$ 

# Einstichproben-T-Test | (2) Definition und Analyse der Teststatistik

## Theorem (Verteilung der T-Teststatistik)

 $v_1, ..., v_n \sim N(\mu, \sigma^2)$  sei die Stichprobe eines Normalverteilungmodells,  $\bar{v}$  sei das Stichprobenmittel, S sei die Stichprobenstandardabweichung, und es sei  $\mu_0 \in \mathbb{R}$ . Dann ist die T-Teststatistik

$$T := \sqrt{n} \left( \frac{\bar{v} - \mu_0}{S} \right) \tag{23}$$


eine nichtzentrale t-Zufallsvariable mit Nichtzentralitätsparameter

$$d = \sqrt{n} \left( \frac{\mu - \mu_0}{\sigma} \right) \tag{24}$$


und Freiheitsgradparameter n-1, es gilt also  $T \sim t(d,n-1)$ 

# Einstichproben-T-Test | (2) Definition und Analyse der Teststatistik

Wahrscheinlichkeitsdichtefunktionen nichtzentraler t-Verteilungen



20. Skizzieren Sie qualitativ die Testgütefunktionen eines ZETTs für verschiedene kritische Werte.



21. Wie muss der kritische Wert eines ZETTs definiert sein, damit der Test ein Level- $\alpha_0$ -Test ist?

# Theorem (Testumfangkontrolle)


 $\phi$  sei der oben definierte Test. Dann ist  $\phi$  ein Level- $\alpha_0$ -Test mit Testumfang  $\alpha_0$ , wenn der kritische Wert definiert ist durch


$$k_{\alpha_0} := \Psi^{-1} \left( 1 - \frac{\alpha_0}{2}; n - 1 \right),$$
 (25)

wobei  $\Psi^{-1}(\cdot;n-1)$  die inverse KVF der t-Verteilung mit n-1 Freiheitsgraden ist.

# 22. Skizzieren Sie qualitativ die Bestimmung des kritischen Wertes $k_{\alpha_0}$ bei einem zws Einstichproben-T-Test.

Wahl von  $k_{\alpha_0}:=\Psi^{-1}(1-rac{\alpha_0}{2};n-1)$  mit n=12,  $\alpha_0:=0.05$  und Ablehnungsbereich





## SKF 23. Durchführung eines ZETTs

## 23. Erläutern Sie das praktische Vorgehen zur Durchführung eines ZETTs.

- Man nimmt an, dass ein vorliegender Datensatz  $y_1,...,y_n$  eine Realisation von  $v_1,...,v_n \sim N(\mu,\sigma^2)$  mit unbekannten Parametern  $\mu$  und  $\sigma^2>0$  ist.
- Man möchte entscheiden ob für ein  $\mu_0 \in \mathbb{R}$  eher  $H_0: \mu = \mu_0$  oder  $H_1: \mu \neq \mu_0$  zutrifft.
- Man wählt ein Signifikanzlevel  $\alpha_0$  und bestimmt den zugehörigen Freiheitsgradparameter-abhängigen kritischen Wert  $k_{\alpha_0}$ . Zum Beispiel gilt bei Wahl von  $\alpha_0:=0.05$  und n=12, also Freiheitsgradparameter 11, dass  $k_{0.05}=\Psi^{-1}(1-0.05/2;11)\approx 2.20$  ist.
- ullet Anhand von  $n, \mu_0, ar{v}$  und  $s_n$  berechnet man die Realisierung der T-Teststatistik

$$t := \sqrt{n} \left( \frac{\bar{y} - \mu_0}{s} \right) \tag{26}$$


- Wenn t größer-gleich  $k_{\alpha_0}$  ist oder wenn t kleiner- gleich  $-k_{\alpha_0}$  ist, lehnt man die Nullhypothese ab, andernfalls lehnt man sie nicht ab.
- Die oben entwickelte Theorie garantiert dann, dass man in höchstens  $\alpha_0 \cdot 100$  von 100 Fällen die Nullhypothese fälschlicherweise ablehnt.

#### SKF 24. Powerfunktion des ZETTs


#### 24. Von welchen Werten hängt die Powerfunktion eines ZETTs ab?

Die Powerfunktion eines zweiseitigen Einstichproben T-Tests hängt bei festgelegtem  $\alpha_0$  vom wahren, aber unbekannten Parameterwert  $\delta=\sqrt{n}\frac{\mu-\mu_0}{\sigma}$  und von der Stichprobengröße n ab.

25. Skizzieren Sie qualitativ die Powerfunktion des ZETTs bei fester Stichprobengröße.



# 26. Skizzieren Sie qualitativ die Powerfunktion des ZETTs bei festem Erwartungswertparameter.



#### SKF 27. Durchführung einer Poweranalyse

# 27. Erläutern Sie das favorisierte praktische Vorgehen zur Durchführung einer Poweranalyse.

#### Generell wird folgendes Vorgehen favorisiert

- Man legt das Signifikanzlevel  $\alpha_0$  fest und evaluiert die Powerfunktion.
- Man wählt einen Mindestparameterwert  $d^*$ , den man mit  $\pi(d,n)=\beta$  detektieren möchte.
- Ein konventioneller Wert ist  $\beta = 0.8$ .
- Man liest die für  $\pi(d=d^*,n)=\beta$  nötige Stichprobengröße n ab.

# 28. Erläutern Sie die Motivation zur Auswertung von p-Werten.

- ullet Es werde ein zweiseitiger Einstichproben-T-Test mit n=12 und  $lpha_0=0.05$  durchgeführt.
  - o  $H_0$  wird abgelehnt, wenn  $|T| \geq 2.20$ .
- Nehmen wir an, es werde t = 2.26 beobachtet.
  - Das Testergebnis lautet "H<sub>0</sub> Ablehnen".
- Nehmen wir an, es werde t = 3.81 beobachtet.
  - Das Testergebnis lautet "H<sub>0</sub> Ablehnen".
- Der alleinige Bericht des Testergebnis supprimiert interessante Information.
- $\Rightarrow$  Neben der Testumfangkontrolle durch z.B.  $\alpha_0=0.05$  ist es daher üblich, alle Werte von  $\alpha_0$  anzugeben, für die ein Level- $\alpha_0$ -Test zum Ablehnen von  $H_0$  führen würde.
  - $\circ \ \ \text{Bei} \ t=2.26 \ \text{w\"urde} \ H_0 \ \text{f\"ur jedes} \ \alpha_0 \ \text{mit} \ 2.26 \geq \Psi^{-1} \left(1-\frac{\alpha_0}{2};11\right) \ \text{abgelehnt werden}.$
  - o Bei t=3.81 würde  $H_0$  für jedes  $\alpha_0$  mit  $3.81 \geq \Psi^{-1}\left(1-\frac{\alpha_0}{2};11\right)$  abgelehnt werden.
- Das kleinste Signifikanzlevel  $\alpha_0$ , bei dem man  $H_0$  basierend auf einem Wert der Teststatistik ablehnen würde, wird p-Wert des Wertes der Teststatistik genannt.

29. Definieren Sie den Begriff des p-Werts.

# Definition (p-Wert)

 $\phi$  sei ein kritischer Wert-basierter Test. Der p-Wert ist das kleinste Signifikanzlevel  $\alpha_0$ , bei welchem man die Nullhypothese basierend auf einem vorliegendem Wert der Teststatistik ablehnen würde.

Beispiel (Zweiseitiger Einstichproben-T-Test mit einfacher Nullhypothese)

• Bei T=t würde  $H_0$  für jedes  $\alpha_0$  mit  $|t|\geq \Psi^{-1}\left(1-\frac{\alpha_0}{2};n-1\right)$  abgelehnt werden. Für diese  $\alpha_0$  gilt, wie unten gezeigt,

$$\alpha_0 \ge 2\mathbb{P}(T \ge |t|). \tag{27}$$

• Das kleinste  $\alpha_0 \in [0,1]$  mit  $\alpha_0 \geq 2\mathbb{P}(T \geq |t|)$  ist dann  $\alpha_0 = 2\mathbb{P}(T \geq |t|)$ , also folgt

$$\text{p-Wert} = 2\mathbb{P}(T \ge |t|) = 2(1 - \Psi(|t|; n - 1)). \tag{28}$$

• Zum Beispiel ist bei n=12 für T=2.26 der p-Wert 0.045, für T=-2.26 ist der p-Wert auch 0.045, für T=3.81 ist der p-Wert 0.003 und für T=-3.81 ist der p-Wert auch 0.003.

30. Geben Sie das Theorem zur Dualität von Konfidenzintervallen und Hypothesentests wieder.

# Theorem (Dualität von Konfidenzintervallen und Hypothesentest)

 $v=v_1,...,v_n\sim p_{\theta}$  sei eine Stichprobe mit Ergebnisraum  $\mathcal Y$  und Parameterraum  $\Theta$ . Weiterhin sei  $[G_u(v),G_o(v)]$  ein  $\delta$ -Konfidenzintervall für  $\theta$ . Dann ist der Hypothesentest

$$\phi_{\theta}: \mathcal{Y} \to \{0, 1\}, y \mapsto \phi(y) := \begin{cases} 0, & [G_{u}(y), G_{o}(y)] \ni \theta_{0} \\ 1, & [G_{u}(y), G_{o}(y)] \not\ni \theta_{0} \end{cases}$$
(29)

ein Test vom Signifikanzlevel  $\alpha_0=1-\delta$  für die Hypothesen

$$\Theta_0 := \{\theta_0\} \text{ und } \Theta_1 := \Theta \setminus \{\theta_0\}. \tag{30}$$

#### SKF 31. Dualität von Konfidenzintervallen und Hypothesentests

#### 31. Erläutern Sie die Dualität von Konfidenzintervallen und Hypothesentests.

Mit  $\delta$ -Konfidenzintervallen können Tests vom Signifikanzniveau  $\alpha_0 = 1 - \delta$  konstruiert werden.

Dieser Test ergibt den Wert 0 (Nullhypothese *nicht* ablehnen), wenn das Konfidenzintervall einen Nullhypothesenparameterwert einschließt und den Wert 1, wenn (Nullhypothese ablehnen), wenn das Konfidenzintervall den Nullhypothesenparameterwert nicht überdeckt.